
Reporte técnico de selección e implementación de modelos

Proyecto: Dashboard analítico para el diseño y monitoreo de un seguro agrícola indexado para café en Colombia

Holman Zarta Zarate

Fabian Jiménez Villamil

1. Objetivo del módulo y del artefacto

El Módulo 2 tiene como propósito implementar, comparar y documentar alternativas de modelado que respondieran a los requerimientos del artefacto analítico propuesto. Más que buscar un único modelo perfecto, el objetivo fue identificar qué combinaciones de datos, variables y técnicas ofrecían mayor valor según la frecuencia de análisis y el rol esperado dentro de la herramienta.

Desde el punto de vista de negocio, el artefacto debía apoyar la reducción del riesgo base, la actualización periódica de primas, el monitoreo territorial del producto y la visualización técnica de índices, métricas y señales de activación. Desde el punto de vista analítico, el reto fue evaluar si las variables climáticas y económicas permitían aproximar mejor la variación productiva del café, reconociendo restricciones de frecuencia, cobertura y granularidad.

2. Datos, tratamiento previo y verificación de supuestos

La implementación se estructuró sobre una lógica multifrecuencia. Se partió de una base panel departamental semanal, se generó una base mensual agregada y posteriormente una base anual. Esta decisión respondió a la necesidad de contrastar qué frecuencia era más útil para el artefacto y qué tan estable era la señal productiva al cambiar la granularidad temporal.

La variable objetivo semanal ``produccion_semanal_proxy_t`` no corresponde a producción observada. Se construyó como una proxy operativa derivada de producción anual observada, estacionalidad mensual nacional y una regla de desagregación por calendario. Esta regla permitió evitar leakage, es decir, impedir que las mismas variables climáticas usadas como covariables explicativas quedaran también embebidas en la Y.

Para construir las capas mensual y anual se aplicaron reglas de agregación diferenciadas: suma para variables de flujo y targets productivos, promedio para variables climáticas de estado o intensidad, y máximo o promedio para dummies de eventos. Las variables estructurales repetidas dentro del período se conservaron sin sumarlas múltiples veces.

Para mayor detalle técnico sobre tratamiento de datos, reglas de transformación, construcción de variables y trazabilidad de experimentos, se documentó un repositorio complementario en [Git Hub](#) que acompaña este reporte y permite reproducir la lógica general del proceso.

Tabla 1. Estructura de datos por frecuencia y justificación técnica

Frecuencia	Unidad analítica	Justificación técnica	Uso dentro del artefacto
Weekly	Departamento-semana	Maximiza número de observaciones y permite seguimiento fino, pero usa una Y proxy y presenta alta influencia territorial.	Monitoreo, simulación operativa y soporte del dashboard.
Monthly	Departamento-año-mes	Reduce ruido de alta frecuencia y preserva mejor la consistencia productiva que weekly.	Puente analítico-operativo, comparación entre zonas y soporte al pricing.
Annual	Departamento-año	Es la capa conceptualmente más cercana a producción/rendimientos observados, pero con muestra muy pequeña.	Contraste metodológico y documentación de limitaciones.

Se evaluó también un proxy nacional semanal agregada. Sin embargo, dicha serie resultó poco valiosa para el modelamiento porque suavizaba la heterogeneidad territorial y perdía capacidad para distinguir diferencias de riesgo entre zonas. Por ello, el eje del modelamiento se trasladó a la base panel departamental.



3. Selección de variables, modelos candidatos y criterios técnicos

Las variables se agruparon en cuatro familias: (i) climáticas centrales, (ii) climáticas derivadas, (iii) económicas de contexto y (iv) estructurales productivas. Esta separación permitió construir experimentos incrementales y evaluar si cada familia agregaba valor predictivo o únicamente aportaba contexto.

Los modelos candidatos se eligieron de forma conservadora según el tamaño muestral y la complejidad esperada de la relación entre variables. Los baselines simples sirvieron para establecer una referencia mínima; Ridge permitió incorporar regularización e interpretabilidad; Random Forest se usó para capturar relaciones no lineales y posibles interacciones; y XGBoost se probó en weekly y monthly como alternativa de boosting, donde el número de observaciones era suficiente para justificar su inclusión. En annual no se utilizaron modelos más complejos debido a que la muestra disponible (20 observaciones) hacía metodológicamente más prudente mantener modelos parsimoniosos.

Tabla 2. Modelos candidatos por frecuencia

Frecuencia	Modelos candidatos	Motivo técnico de inclusión
Weekly	Dummy, Ridge, Random Forest, XGBoost	Mayor número de observaciones; se evaluaron modelos lineales y no lineales para capturar dinámica operativa.
Monthly	Dummy, Ridge, Random Forest, XGBoost	Frecuencia intermedia con tamaño muestral suficiente para comparar interpretabilidad vs. flexibilidad.
Annual	Dummy, Ridge	Muestra reducida (20 observaciones); se privilegió parsimonia y estabilidad sobre complejidad.

3.1 Supuestos y criterios técnicos por familia de modelos

Los modelos candidatos no se eligieron únicamente por desempeño esperado, sino también por su compatibilidad con el tamaño muestral, la naturaleza de las variables y el nivel de interpretabilidad requerido por el artefacto. En particular, los modelos lineales regularizados se consideraron apropiados cuando se buscaba parsimonia, estabilidad e interpretación de efectos promedio, mientras que los modelos basados en árboles se usaron para capturar relaciones no lineales e interacciones entre variables climáticas, económicas y productivas.

En términos de supuestos, Ridge exige una relación aproximadamente estable entre covariables y target, y resulta útil cuando existe posible multicolinealidad entre predictores. Random Forest y XGBoost relajan supuestos de linealidad y permiten capturar interacciones de mayor complejidad, aunque a costa de menor interpretabilidad estructural. Dado que la frecuencia anual solo ofrecía 20 observaciones, se privilegió un criterio conservador de parsimonia y estabilidad, descartando modelos más complejos por riesgo de sobreajuste y baja robustez fuera de muestra.

Además, la selección de variables se hizo bajo control explícito de leakage: no se incluyeron como covariables aquellas variables que participaban directamente en la construcción del target proxy o que incorporaban información futura incompatible con el esquema de validación temporal.

4. Esquema de entrenamiento, validación y métricas


Todas las corridas siguieron un split temporal consistente: entrenamiento 2021–2022, validación 2023 y prueba 2024. Esta elección respondió al objetivo de emular un escenario real de generalización hacia adelante, evitando fuga de información futura y manteniendo coherencia cronológica.

Familia / modelo	Frecuencias	Parametrización base	Justificación
Dummy mean	Weekly, Monthly, Annual	Predicción constante con media del train	Benchmark mínimo
RidgeCV	Weekly, Monthly, Annual	α s = logspace(-3,3,20)	Regularización, interpretabilidad y estabilidad
Random Forest	Weekly, Monthly	n_estimators = 300; max_depth = 8 o 3 según experimento; min_samples_leaf = 3 o 5; random_state = 42	Capturar no linealidad e interacciones
XGBoost	Weekly, Monthly	n_estimators = 300; max_depth = 4; learning_rate = 0.05; subsample = 0.9; colsample_bytree = 0.9; objective = reg:squarederror	Modelo boosting para comparación flexible

La calibración no se orientó a una búsqueda exhaustiva de hiperparámetros, sino a una comparación metodológicamente consistente entre familias de modelos, priorizando trazabilidad, comparabilidad y tiempo disponible del proyecto.

Las métricas utilizadas fueron RMSE, MAE, MAPE, R^2 y correlación. RMSE y MAE permitieron evaluar magnitud del error; MAPE facilitó interpretar el error relativo; R^2 aportó una lectura de capacidad explicativa; y la correlación se usó como medida complementaria para verificar qué tan bien el modelo seguía la dinámica general, incluso cuando el R^2 se veía afectado por muestras pequeñas o por compresión del rango.

Además de las métricas, se realizaron verificaciones de consistencia: revisión de semanas incompletas, chequeo de agregación weekly → monthly → annual y control explícito de leakage en la selección de covariables.



5. Resultados, interpretación y selección de modelos

Tabla 4. Modelos seleccionados y rol analítico

Frecuencia	Modelo seleccionado	Rol dentro del artefacto	Hallazgo principal
Weekly	V7_clima_mas_economicas_rf	Capa operativa semanal	Mejor desempeño semanal, pero con fuerte influencia territorial.
Monthly	M6_clima_econ_struct_rf	Capa operativa mensual	Mejor ajuste, aunque dominado por variables estructurales.
Monthly (referencia)	M5_clima_econ_rf	Referencia climática mensual	Más limpio para interpretar la lógica climática del seguro indexado.
Annual	A1_baseline_ridge	Contraste metodológico	La señal climática anual agregada no superó al baseline territorial-temporal.


5.1 Hallazgos en frecuencia weekly

El mejor desempeño semanal se obtuvo con `V7\_clima\_mas\_economicas\_rf`, que superó a los baselines y a las alternativas lineales. Este resultado confirmó que, a escala operativa, la combinación de clima derivado y variables económicas aportaba valor frente a usar únicamente señales climáticas simples. Sin embargo, el análisis posterior mostró que buena parte de la señal provenía del componente territorial, lo que limita interpretar weekly como validación climática pura del riesgo productivo.


Modelo	val_RMSE	val_MAPE%	val_R ²	test_RMSE	test_MAPE%	test_R ²	test_Corr	Nota
V7_clima_mas_economicas_rf	15.32	18.24	0.781	30.60	19.08	0.649	0.940	Seleccionado
V5_clima_crudo_rf	15.40	18.71	0.779	36.01	20.56	0.511	0.877	2do
V8_clima_derivado_xgb	15.95	18.24	0.762	36.56	21.87	0.499	0.888	
V6_clima_derivado_rf	16.55	20.21	0.744	36.07	21.56	0.512	0.863	
V4_indice_base_ridge	17.21	16.37	0.723	43.58	31.13	0.288	0.980	
V1_baseline_ridge	17.54	16.67	0.713	44.23	32.41	0.266	0.910	
V2_clima_crudo_ridge	18.39	17.96	0.684	46.65	37.97	0.184	0.911	
V3_clima_derivado_ridge	18.73	18.35	0.673	47.58	37.90	0.151	0.904	
V0_dummy_mean	32.83	52.27	-0.006	54.10	50.71	-0.098	~0	Referencia

TOP VARIABLES — V7 (conceptual)

Visual conceptual basada en resultados del experimento; ver tabla de métricas del reporte.



IMPORTANCIA POR FAMILIA — V7



HALLAZGO CLAVE

El weekly mostró una dependencia muy alta del componente territorial, lo cual limita su interpretación como señal causal del índice.


5.2 Hallazgos en frecuencia monthly

En monthly, `M6\_clima\_econ\_struct\_rf` obtuvo el mejor ajuste. No obstante, la revisión de importancia por familias mostró dominancia de variables estructurales, especialmente `area\_cosechada\_departamental\_ha`. Por ello, el monthly se interpretó con una doble lectura: M6 como mejor capa operativa y `M5\_clima\_econ\_rf` como referencia más limpia para sostener la lógica climática del seguro indexado. Esta frecuencia resultó ser la mejor capa intermedia del proyecto, al conservar mayor coherencia productiva que weekly sin perder utilidad para la herramienta.


Modelo	val_RMSE	val_MAPE%	val_R ²	test_RMSE	test_MAPE%	test_R ²	test_Corr	Nota
M6_clima_econ_struct_rf	62.92	17.65	0.804	144.72	19.82	0.593	0.883	Mejor ajuste
M7_clima_econ_xgb	62.97	16.75	0.804	150.30	20.33	0.561	0.930	
M5_clima_econ_rf	66.34	18.32	0.782	149.60	20.40	0.565	0.908	Ref. Climática
M4_clima_rf	72.81	20.54	0.737	161.85	21.44	0.491	0.840	
M1_baseline_ridge	78.89	17.70	0.692	197.84	33.18	0.240	0.907	
M2_clima_ridge	79.49	17.93	0.687	202.65	36.27	0.202	0.903	
MO_dummy	142.55	52.57	-0.006	238.11	50.78	-0.101	NaN	Referencia

TOP VARIABLES — M6 (conceptual)

Visual conceptual basada en resultados del experimento.



IMPORTANCIA POR FAMILIA — M6



M6 vs M5

MOTOR OPERATIVO
M6_clima_econ_struct_rf
Mejor ajuste global mensual. Capa operativa principal del artefacto.
REFERENCIA CLIMÁTICA
M5_clima_econ_rf
Mejor alineado con la lógica del seguro indexado. Referencia técnica climática.

5.3 Hallazgos en frecuencia anual

En anual, el mejor desempeño correspondió al baseline Ridge (`A1\_baseline\_ridge`) tanto para rendimiento como para producción. Las versiones con clima anual agregado y clima más economía no superaron de manera consistente al baseline. Con solo 20 observaciones, el ejercicio anual fue valioso principalmente como contraste metodológico: mostró que la señal climática agregada a esa escala y con el esquema actual de variables no era suficiente para desplazar el componente territorial-temporal.

TARGET: rendimiento_departamental_t_ha					
Modelo	val_RMSE	val_MAPE%	val_R ²	test_RMSE	test_R ²
A1_baseline_ridge	0.120	8.04	0.626	0.427	-6.34
A2_clima_ridge	0.153	15.66	0.394	0.269	-1.91
A3_clima_econ_ridge	0.158	16.33	0.353	0.253	-1.57
AO_dummy	0.200	19.43	-0.042	0.299	-2.60

TARGET: produccion_anual_departamental_t					
Modelo	val_RMSE	val_MAPE%	val_R ²	test_RMSE	test_R ²
A1_baseline_ridge	643.78	10.04	0.818	2030.09	0.252
A3_clima_econ_ridge	1388.69	36.27	0.152	2992.64	-0.626
AO_dummy	1514.17	48.08	-0.008	2502.16	-0.136
A2_clima_ridge	1670.95	46.87	-0.227	3495.36	-1.217



Nota metodológica: El anual se conserva como contraste metodológico, no como núcleo operativo del artefacto. Los modelos con clima no superaron claramente al baseline.

6. Limitaciones, ajustes y lectura final del módulo

Los resultados mostraron que no era metodológicamente correcto insistir en una narrativa de modelo único dominante. La weekly proxy es una Y operativa y no una observación directa; weekly quedó fuertemente influenciado por territorio; monthly mejoró la utilidad del artefacto, pero su mejor ajuste dependió de estructura productiva; y annual resultó demasiado pequeño y agregado para que el clima desplazara al baseline.


Lejos de invalidar el proyecto, estos hallazgos permitieron reorganizar la solución hacia una arquitectura multifrecuencia más sólida: weekly para monitoreo y simulación, monthly como puente analítico-operativo y annual como contraste metodológico. Esta lectura hace explícitas las limitaciones de datos, **evita sobre prometer** capacidad predictiva y fortalece la utilidad real del artefacto.

- La Y semanal no debe interpretarse como producción observada.
- La base panel departamental fue más valiosa que la proxy nacional porque preservó heterogeneidad territorial.
- Monthly ofreció el mejor equilibrio entre consistencia productiva y utilidad operativa.
- Annual fue útil para documentar limitaciones y no como capa predictiva final del sistema.

7. Plan de implementación hacia el prototipo final

De cara al siguiente módulo, la herramienta analítica se plantea como un sistema integrado de monitoreo, comparación territorial, simulación de escenarios y apoyo a la definición de primas y triggers. Weekly puede alimentar tableros, alertas y sensibilidad; monthly puede apoyar análisis comparativos, comparación entre zonas y actualización operativa; y annual queda como soporte metodológico y de documentación.

Los desarrollos pendientes incluyen la consolidación visual del dashboard, automatizaciones de actualización, generación de reportes técnicos, incorporación explícita de criterios de activación del seguro y mejora incremental de la lógica de pricing. En consecuencia, el prototipo funcional no dependerá de un único modelo, sino de la integración coherente de las tres capas desarrolladas.



8. Conclusión

El principal resultado de esta entrega no es únicamente la selección de V7, M6/M5 o A1, sino la consolidación de una ruta metodológica clara, trazable y defendible. Los experimentos permitieron identificar qué modelos aportan valor en cada frecuencia, qué limitaciones deben comunicarse con transparencia y cómo se reubica cada capa dentro del artefacto final del seguro indexado. En esa medida, el proyecto se justifica mejor como una solución analítica integrada por capas que como un modelo climático único y definitivo.